

Resumo Geral e Links de Entrega

Global Solution — Processamento de Linguagem Natural, Chatbots & Virtual Agents

William Stahl Sanches Furquim Garcia — RM 562800
Paulo Gabriel Pessoa da Silva — RM 566446

● Links de Entrega

Entregavel	Link	Plataforma
Video de Apresentacao	https://youtu.be/VzHm4r4-7cs	YouTube
Notebook Google Colab	https://colab.research.google.com/drive/1FEtYMCBF03pra91K8JKXOZQzksSjuhZ4?usp=sharing	Google Colab

● Resumo Geral do Projeto

Assistente tecnico baseado em RAG (Retrieval-Augmented Generation) especializado em edificios verdes e Net Zero de Energia e Agua. O sistema responde perguntas tecnicas citando obrigatoriamente a fonte de cada informacao, eliminando alucinacoes e garantindo rastreabilidade total. O pipeline integra embeddings multilinguais, ChromaDB com persistencia em disco e Llama 3.3 70B via Groq/OpenRouter, cobrindo eficiencia energetica, gestao hidrica e certificacoes como LEED, AQUA-HQE e GBC Brasil.

● Pipeline Completo

Etapa	Detalhe	Resultado
Corpus	10 documentos tecnicos (LEED, AQUA-HQE, ABNT NBR 15575, GBC Brasil, IEA, PROCEL, CBCS, CEPEL, Carbon Trust, ANA)	3 categorias, 2 subcategorias
Pre-processamento	Extracao de texto, remocao de ruidos de PDF, normalizacao de encoding e espacos	10 documentos limpos
Chunking	Segmentacao semantica com overlap de 64 tokens e limite de 512 tokens por chunk	19 chunks, media 387 tokens
Embeddings	paraphrase-multilingual-mpnet-base-v2 — suporte ao portugues e ingles, dim 768	Vetores normalizados
Banco vetorial	ChromaDB com persistencia em disco e metadados por chunk (titulo, fonte, categoria, subcategoria, ano)	19 vetores indexados
LLM	llama-3.3-70b-versatile via Groq meta-llama/llama-3.3-70b-instruct via OpenRouter	Respostas com fonte citada

● Distribuicao do Corpus

Agrupamento	Valor	Chunks	%
Categoria	norma_certificacao	8	42%
	manual_tecnologia	6	32%
	relatorio_tecnico	5	26%
Subcategoria	energia	9	47%
	energia_e_agua	6	32%
	agua	4	21%

● Avaliacao — 10 Perguntas Tecnicas

Resultado	Qtd.	%
Respondida com sucesso e fonte verificada	8	80%
Respondida parcialmente	1	10%
Sem cobertura no corpus (comportamento correto do sistema)	1	10%

● Comparacao RAG vs LLM Puro

Dimensao	COM RAG	SEM RAG
Precisao numerica	Valor exato com fonte (ex: 30-40% de economia com reuso de aguas cinzas [ANA, 2005])	Faixa imprecisa sem fonte (ex: 20-50%)
Rastreabilidade	Cita titulo, organizacao e ano em cada dado tecnico	Nenhuma fonte citada
Alucinacao	Zero — restrito ao corpus indexado	Presente — inventa requisitos inexistentes
Cobertura	Informa o usuario quando nao ha dados no corpus	Responde sempre, mesmo sem base factual

● Tecnologias Utilizadas

Componente	Tecnologia
Embedding	sentence-transformers/paraphrase-multilingual-mpnet-base-v2
Banco vetorial	ChromaDB (persistencia em disco)
LLM	llama-3.3-70b-versatile via Groq meta-llama/llama-3.3-70b-instruct via OpenRouter
Tokenizacao	tiktoken (cl100k_base)
Visualizacao	t-SNE (scikit-learn) + matplotlib
Orquestracao	Pipeline RAG customizado em Python